

Lab 08: Machine Learning pe date omice

Am folosit un set de date de tip "expression matrix" cu etichete (Condition) și variabile (gene/features).
am facut:

1. clasificare supervised (Random Forest),
2. explorare unsupervised (PCA + KMeans) și
un pseudo-labeling de tipul semi-supervised.

datele mele sunt in: `expression\_matrix\_unknown13m.csv`
-y (label): `Condition`
-X (features): Gene001...Gene050 (aici am valori numerice)

și ca și limitare importantă: dataset-ul este mic, deci rezultatele pot varia și nu sunt stabile statistic.

La partea de supervised ML, Random Forest, am antrenat un RandomForestClassifier (n_estimators=300) pe
-`classification\_report\_unknown13m.txt`
-`confusion\_rf\_unknown13m.png`
-`feature\_importance\_unknown13m.csv`

am vazut ca la confusion matrix arată unde modelul greșete între clase și ca la feature importances îmi da un

La logistic regression am rulat și logistic regression cu scaling (StandardScaler) și am comparat cu RF, iar rez

ca și diferență de concept, la LogReg am un model linear (decizie liniară în spațiul feature-urilor), iar la RF a

La unsupervised ML și PCA + KMeans am aplicat StandardScaler + PCA (2 componente) pentru vizualizare, a

-dacă etichetele (Condition) se aliniază cu clusterelor, atunci structura nesupravegheată recuperează parțial
-probe "greșite" pot apărea din zgomot, outliers sau lipsă de separare

Unde am avut semi-supervised (pseudo-labeling) am simulat lipsa etichetelor: ~40% etichete marcate ca "unknown"
întai am facut RF antrenat doar pe date etichetate, după care prezic pseudo-labels pentru cele fără etichetă și

Rezumatul e în `semi\_supervised\_unknown13m.txt`.

-performanța poate crește dacă pseudo-labels sunt corecte și structura e clară, dar poate și scădea dacă p

ca și interpretare biologică (la nivel de lab), cele mai importante "gene" (features) sunt cele cu importanță mare
Doar că aici, deoarece datele sunt de demo și dataset-ul este mic, interpretarea biologică trebuie tratată doar

Am avut și limitări de genul nr mic de probe (și asta mi-a cam dat rezultate instabile), un posibil bias din modul